

Uczenie maszynowe w Pythonie od podstaw

prof. UAM dr hab. Tomasz Górecki

`tomasz.gorecki@amu.edu.pl`

Zakład Statystyki Matematycznej i Analizy Danych
Wydział Matematyki i Informatyki
Uniwersytet im. Adama Mickiewicza w Poznaniu

XENSTATS

Rodzaje błędów

Błąd pomiarowy

Rachunek błędów jest to zespół zagadnień na pograniczu metrologii, statystyki i matematyki. Obejmuje zasady opracowywania i prezentacji wyników doświadczalnych. Wszelkie wyniki pomiarów pozbawione dyskusji błędów, a zwłaszcza określenia **błędu pomiarowego** (różnica pomiędzy wynikiem pomiaru, a prawdziwą wartością), są w istocie wyłączone wskazaniami. Błąd pomiarowy nie powstaje jedynie w wyniku pomyłki, jest on nieodłącznym czynnikiem procesu pomiarowego.


Rodzaje błędów

Elementy błędu pomiarowego

Błąd pomiarowy składa się z dwóch elementów:

- ❶ **Błąd statystyczny, przypadkowy** – błąd wynikający z ogółu wpływów środowiska, których często nie można zidentyfikować czy wyeliminować. Charakteryzuje się niewielką wartością oraz losowym znakiem i wartością. Związany jest z pomiarem i nie można go całkowicie wyeliminować. Redukuje się go poprzez powtarzanie pomiarów i uśrednianie.
- ❷ **Błąd systematyczny** – błąd wynikający z zastosowanej metody pomiaru lub innych przyczyn (np. niedających się wykluczyć, ale znanych zjawisk mających wpływ na pomiar). Charakteryzuje się stałym znakiem, tj. zawsze powoduje zawyżenie lub zaniżenie wartości wyniku pomiaru, wpływa jednakowo na wszystkie pomiary. Błąd systematyczny o znanej wartości nazywamy **poprawką**.

Rodzaje błędów pomiarowych



Obserwacja odstająca

Błąd gruby

Wyróżnia się również **błąd gruby (pomyłkę)**, który jest pewną odmianą błędu przypadkowego, w sensie jego przypadkowego pojawiania się. Ma miejsce, gdy któryś z wyników pomiaru odbiega znacznie od pozostałych. Możemy wówczas podejrzewać, że pewne zdarzenie wypaczyło wynik eksperymentu. Błędy grube mogą wynikać np. ze złego odczytania skali przyrządu pomiarowego, pomyłki przy zapisie miejsca przecinka, pomiaru błędnego obiektu. Wyniki takie powinny zostać odrzucone podczas analizy statystycznej.

Obserwacja odstająca

Obserwacja odstająca (ang. *outlier*) to obiekt, który tak bardzo różni się od innych obserwacji, iż powstaje podejrzenie, że został on wygenerowany przez inny mechanizm.

Obserwacja odstająca

Eliminacja błędów grubych (obserwacji odstających)

- ❶ Filtr HAMPELA – odrzucamy obserwacje spoza przedziału

$$[\tilde{X} - 4.5 \cdot \text{MAD}, \tilde{X} + 4.5 \cdot \text{MAD}],$$

gdzie $\tilde{X}$ jest medianą zbioru $\mathbf{X} = \{X_1, X_2, \dots, X_n\}$ oraz

$$\text{MAD}(X) = \text{Mediana}|\mathbf{X} - \tilde{X}|$$

jest bezwzględnym odchyleniem medianowym (*ang. median absolute deviation*).

Obserwacja odstająca

Eliminacja błędów grubych (obserwacji odstających)


2 Test statystyczny:

- Test DIXONA (test Q) – stosujemy go dla próbek o licznosci do 30, dodatkowo zakładamy normalność danych.
- Test GRUBBSA – najpopularniejszy, zakładamy normalność danych.
- Test ROSNERA – do wykrywania wielu obserwacji odstających równocześnie.

Observacja odstająca

Eliminacja błędów grubych (obserwacji odstających)

- Wykres pudełkowy.




Obserwacja odstająca

Eliminacja błędów grubych (obserwacji odstających)

- ④ Las izolacyjny (*ang. isolation forest*) – używany zwłaszcza dla danych wielowymiarowych. Tworzymy drzewa decyzyjne stosując losowe podziały. Obserwacje, które stają się szybko małymi liśćmi są bardziej prawdopodobne jako obserwacje odstające, ponieważ anomalie są bardziej podatne na izolację przy losowym podziale.

Obserwacja odstająca



Obserwacja odstająca

Eliminacja błędów grubych (obserwacji odstających) – przykład


Wyniki oznaczeń zawartości jonów miedzi (Cu^{2+}) w próbce ścieków [mg/dm^3] wyglądają następująco: 0,875, 0,863, 0,876, 0,868, 0,771, 0,881, 0,878, 0,869, 0,866. Czy jakaś z obserwacji może zostać uznana za odstającą, jeśli zakładamy, że zawartość jonów ma rozkład normalny?

P-wartość

P-wartość (ang. p-value) to prawdopodobieństwo (przy prawdziwości H_0) otrzymania wartości równej lub bardziej ekstremalnej niż zaobserwowana. P-wartość pozwala bezpośrednio ocenić wiarygodność hipotezy. Im p-wartość jest większa, tym bardziej brak nam podstaw, aby w nią wątpić. Mała p-wartość świadczy przeciwko hipotezie zerowej.

<u>P-VALUE</u>	<u>INTERPRETATION</u>
0.001	HIGHLY SIGNIFICANT
0.01	
0.02	
0.03	
0.04	SIGNIFICANT
0.049	
0.050	OH CRAP. REDO CALCULATIONS.
0.051	ON THE EDGE OF SIGNIFICANCE
0.06	
0.07	HIGHLY SUGGESTIVE, SIGNIFICANT AT THE $P < 0.10$ LEVEL
0.08	
0.09	
0.099	HEY, LOOK AT THIS INTERESTING SUBGROUP ANALYSIS
≥ 0.1	

P-wartość



Typy braków w danych

Typy brakujących danych (*ang. missing data*) reprezentują zależności statystyczne pomiędzy wartościami zaobserwowanymi cech, a rozkładem prawdopodobieństwa wartości brakujących. Poprawne rozpoznanie typu brakujących danych jest kluczowe w tworzeniu prawidłowych modeli imputacji danych.

- MCAR (*ang. Missing Completely At Random*) – braki nie zależą ani od wartości zaobserwowanych, ani od brakujących.
- MAR (*ang. Missing At Random*) – braki zależą tylko od zaobserwowanych obserwacji, a nie od innych braków.
- MNAR (*ang. Missing Not At Random*) – braki zależą od wartości brakujących.

Typy braków w danych

Types of missingness



**Missing Completely
at Random**

(MCAR)

No systematic relationship
between missing data and
other values

Data entry errors when
inputting data



**Missing at
Random**

(MAR)

Systematic relationship
between missing data and
other observed values

Missing ozone data for high
temperatures



**Missing Not at
Random**

(MNAR)

Systematic relationship
between missing data and
unobserved values

Missing temperature values for
high temperatures

Radzenie sobie z brakami danych


- ❶ Usunięcie wierszy/kolumn z brakami w danych,
- ❷ Uzupełnienie danych (imputacja):
 - ❶ Stała wartość (np. ostatnia zaobserwowana),
 - ❷ Średnia, mediana, dominanta ze znanych wartości,
 - ❸ Estymacja za pomocą modelu predykcyjnego,
 - ❹ Wielokrotna imputacja (MICE, Amelia II) – wykonywane są wielokrotne imputacje na bazie modelu probabilistycznego i ostateczna imputacja jest średnią z wielu imputacji pośrednich.

Kodowanie zmiennych jakościowych

Większość algorytmów uczenia maszynowego/sztucznej inteligencji działa lepiej z liczbowymi danymi wejściowymi. Dlatego jednym z głównych wyzwań, przed którym staje analityk, jest konwersja danych tekstowych/kategorycznych na dane liczbowe. Istnieje wiele sposobów konwersji wartości kategorycznych na wartości liczbowe.

- 1 **Kodowanie etykiet** (*ang. label encoding, ordinal encoding*).
Jeśli istnieje jakaś znana relacja (lub kolejność) pomiędzy poziomami lub etykietami w zmiennej jakościowej, wtedy najlepiej jest użyć techniki kodowania etykiet – konwertowanie etykiet na postać numeryczną.

Kodowanie zmiennych jakościowych




Kodowanie zmiennych jakościowych

- ❷ **Gorące kodowanie** (*ang. one hot encoding*). Chociaż kodowanie etykiet jest proste, ma ono tę wadę, że wartości numeryczne mogą być błędnie interpretowane przez algorytmy jako mające w sobie jakąś hierarchię/porządek. Ten problem porządku jest rozwiązywany w innym powszechnym podejściu alternatywnym, zwanym kodowaniem gorącym. W tej strategii każda wartość kategorii jest przekształcana w nową kolumnę i przypisywana jest do niej wartość 1 lub 0 (notacja dla prawda/fałsz).

Kodowanie zmiennych jakościowych

- ❸ Chociaż to podejście eliminuje problemy związane z hierarchią/porządkiem, ma jednak wadę polegającą na dodaniu większej liczby kolumn do zbioru danych. Może to spowodować, że liczba kolumn znacznie się rozszerzy, jeśli mamy wiele unikalnych wartości w kolumnie kategorii. Zwróćmy uwagę, że w tej technice ostatnia kolumna jest nadmiarowa (jej zawartość wynika z zawartości poprzednich kolumn). Taka wersja kodowania gorącego nazywana jest **kodowaniem naiwnym** (*ang. dummy encoding*). Kodowanie naiwne jest niewielkim ulepszeniem w stosunku do kodowania gorącego, mianowicie wykorzystuje $N - 1$ cech (kolumn) do reprezentowania N etykiet/kategorii.


Kodowanie zmiennych jakościowych



Kodowanie zmiennych jakościowych

- 4 **Kodowanie binarne** (*ang. binary encoding*). Podczas gdy kodowanie gorące rozwiązuje problem nierównych wag nadawanych kategoriom w ramach cechy, nie jest ono zbyt użyteczne, gdy istnieje wiele kategorii, ponieważ spowoduje to utworzenie wielu nowych kolumn, co może skutkować przekleństwem wymiarowości (*ang. curse of dimensionality*). Koncepcja „klątwy wymiarowości” mówi o tym, że w przestrzeniach wielowymiarowych pewne algorytmy przestają działać poprawnie. W takiej sytuacji można spróbować zastosować kodowanie binarne. W tej technice, najpierw kategorie są kodowane jako porządkowe, następnie te liczby całkowite są konwertowane na kod binarny, a ostatecznie cyfry z tego ciągu binarnego są dzielone na osobne kolumny. Dzięki temu dane są kodowane w mniejszej ilości wymiarów niż w przypadku kodowania gorącego.

Kodowanie zmiennych jakościowych



Kodowanie zmiennych jakościowych

- 5 **Kodowanie średnią** (*ang. mean encoding, target encoding*).
Kodowanie średnią jest podobne do kodowania etykiet, z tą różnicą, że tutaj etykiety są skorelowane bezpośrednio z odpowiedzią (zmienną objaśnianą). W kodowaniu średnią dla każdej kategorii etykieta jest ustalana jako średnia wartość zmiennej docelowej na danych uczących dla tej kategorii. Obliczamy statystyki na danych uczących i używamy ich na zbiorze testowym. Jeśli kategoria ze zbioru testowego nie występuje w zbiorze uczącym, używamy statystyki obliczonej na pełnym zbiorze uczącym (bez podziału na kategorie).

Kodowanie zmiennych jakościowych

