

Uczenie maszynowe w Pythonie od podstaw

prof. UAM dr hab. Tomasz Górecki

`tomasz.gorecki@amu.edu.pl`

Zakład Statystyki Matematycznej i Analizy Danych
Wydział Matematyki i Informatyki
Uniwersytet im. Adama Mickiewicza w Poznaniu

XENSTATS

Idea

Termin **regresja** oznacza metodę pozwalającą na zbadanie związku pomiędzy zmiennymi i wykorzystanie tej wiedzy do przewidywania nieznanych wartości jednych wielkości na podstawie innych. W praktyce poszukuje się związku między domniemaną jedną (lub więcej) zmienną **objaśniającą** (**niezależną**), a zmienną **objaśnianą** (**zależną**) Y . Związek ten może być dalej wykorzystywany do prognozowania wartości Y w zależności od X .

Idea

Chcemy zatem odpowiedzieć na pytanie jak zmienia się wartość oczekiwana zmiennej Y w zależności od wartości x zmiennej X , czyli:


$$\mathbb{E}(Y|X) = g(X),$$

gdzie $g(X)$ jest funkcją regresji opisującą poszukiwany związek. Z matematycznego punktu widzenia regresją nazywana jest każda metoda, która umożliwia oszacowanie tego równania.

Idea

REGRESSION

Regression trains models to predict quantitative targets. Example home price.



Chris Albon

Regresja liniowa

Zależności regresyjnej poszukuje się w pewnej zadanej z góry klasie funkcji, na ogół klasie funkcji wielomianowych. Np. gdy za $g(X)$ przyjmiemy funkcję liniową, otrzymamy równanie regresji liniowej:

$$\mathbb{E}(Y|X) = \beta_0 + \beta_1 X,$$

w którym β_0 oraz β_1 są nieznanymi parametrami. W praktyce wygodniej jest posługiwać się następującym modelem regresji liniowej:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

Występujące w równaniu zmienne losowe ε_i nazywane są składnikami losowymi. Zakładamy, że mają one wartość oczekiwaną 0, stałą wariancję równą σ^2 (homoskedastyczność) oraz są nieskorelowane między sobą. Zauważmy, że nie jest wymagane określenie rozkładu składnika losowego (zwykle zakłada się, że jest to rozkład normalny).

Regresja liniowa

W praktyce nie dysponujemy pełną informacją o populacji. Musimy zatem oszacować parametry funkcji regresji na podstawie próby. Odpowiednie oszacowanie ma postać:


$$\hat{y}_i = b_0 + b_1 x_i.$$

Element

$$e_i = y_i - \hat{y}_i$$

nazywany jest **składnikiem resztowym** (**resztą**, **residuum**). Jak jednak znaleźć taką „dobrze dopasowaną” linię prostą? Punktem wyjścia jest suma kwadratów reszt, opisująca rozbieżność pomiędzy wartościami empirycznymi zmiennej zależnej, a jej wartościami teoretycznymi, obliczonymi na podstawie wybranej funkcji. Oszacowania parametrów dobieramy tak, aby suma kwadratów reszt osiągnęła minimum. Metoda ta nosi nazwę **metody najmniejszych kwadratów (MNK)** – *ang. Least Squares Method (LS)*.

Regresja liniowa



Regresja liniowa

Estymatory parametrów otrzymane za pomocą MNK mają postać:


$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

$$b_0 = \bar{y} - b_1 \bar{x}.$$

Tak otrzymane estymatory są najefektywniejszymi i równocześnie nieobciążonymi estymatorami parametrów regresji liniowej.

Współczynnik kierunkowy b_1 nazywamy współczynnikiem regresji liniowej. Odpowiada on na pytanie, jaki jest przeciętny przyrost wartości zmiennej zależnej na jednostkę przyrostu zmiennej niezależnej.

Regresja liniowa



Regresja liniowa

Dokładność oszacowania można ocenić za pomocą **współczynnika determinacji R^2** . Mierzy on jaka część ogólnej zmienności zmiennej zależnej jest wyjaśniona przez regresję liniową (współczynnik determinacji nie ma sensu, jeśli w modelu pominięto wyraz wolny). Dołączenie jednak nowej zmiennej do modelu zawsze zwiększa R^2 . Celem nie jest uzyskanie jak największej wartości tego współczynnika, lecz znalezienie związku między X i Y z rzetelnymi ocenami parametrów. Dlatego w praktyce używamy raczej tzw. poprawionego R^2 . Uwzględnia on, że R^2 jest obliczony z próby i jest trochę „za dobry”, jeśli uogólniamy nasze wyniki na populację. Poprawiony R^2 jest zawsze mniejszy od R^2 . Przyjmuje się, że aby pozytywnie zweryfikować model współczynnik ten musi być większy od 60%. Należy również pamiętać, że taka ocena jakości modelu jest poprawna wtedy i tylko wtedy gdy model jest adekwatny, czyli gdy spełnione są założenia modelu.

Regresja liniowa

Miary oceny jakości modelu – podejście biznesowe

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |e_i| \text{ (ang. Mean Absolute Error),}$$

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \frac{|e_i|}{|y_i|} \times 100 \text{ (ang. Mean Absolute Percentage Error),}$$

$$\text{WAPE} = \frac{\sum_{i=1}^n |e_i|}{\sum_{i=1}^n |y_i|} \times 100 \text{ (ang. Weighted Mean Absolute Percentage Error),}$$

$$\text{WMAPE} = \frac{\sum_{i=1}^n w_i |e_i|}{\sum_{i=1}^n w_i |y_i|} \times 100 \text{ (ang. Weighted Absolute Percentage Error),}$$

gdzie $w_i > 0$ są wagami.

Regresja liniowa

Miary oceny jakości modelu – podejście statystyczne

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n e_i^2 \text{ (ang. Mean Squared Error),}$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2} \text{ (ang. Root Mean Squared Error),}$$

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$

$$R_0^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n y_i^2} = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n y_i^2} \text{ (model bez wyrazu wolnego),}$$

$$R_{\text{adj.}}^2 = 1 - \frac{(1 - R^2)(n - 1)}{n - k}.$$

Wykresy diagnostyczne – wykres dźwigni

Wykorzystywany do zbadania, czy występują obserwacje odstające. Dla każdego residuum obliczana jest siła dźwigni zwana również wpływem (miara wpływu obserwacji na oceny). W modelu adekwatnym siła dźwigni nie powinna być zbyt duża, gdyż oznacza, to że pojedyncza obserwacja ma duży wpływ na oceny parametrów. Przyjmuje się, że obserwacja jest wpływowa jeśli przekracza dwie średnie siły dźwigni. Inną podobną miarą wpływu obserwacji na model jest **odległość COOKA**. Wykazuje ona różnicę między wyznaczonymi wartościami współczynników, a wartościami obliczonymi przy wyłączeniu danego przypadku z obliczeń. Wszystkie odległości powinny być tego samego rzędu. Jeśli nie są, to można przypuszczać, że dany przypadek miał istotny wpływ na obciążenie współczynników równania regresji. Powinna ona być mniejsza od 1, jeśli chcemy uznać model za adekwatny.

Wykresy diagnostyczne – wykres residuów

Wykres przedstawiający na jednej osi wartości dopasowane przez model, a na drugiej residua lub standaryzowane residua.

Powszechną praktyką jest uznawanie, że obserwacja jest odstająca jeżeli jej residuum standaryzowane jest większe co do wartości bezwzględnej od 2. Dla modelu adekwatnego średnia wartość residuum nie powinna zależeć od wartości dopasowania (powinniśmy w wyniku dostać pas punktów losowo rozmieszczonych wokół prostej $y = 0$).

Wykresy diagnostyczne – wykres kwantylowy

Wykresy kwantylowe dla standaryzowanych residuów – powinny wskazać na ich normalność.

Wykresy diagnostyczne – wykres pierwiastków

Wykres, na którym dla każdej wartości zmiennej objaśniającej wyznaczono pierwiastek z wartości bezwzględnej jej residuum standaryzowanego. Nie powinniśmy zaobserwować żadnego trendu. Jeśli takowy występuje, oznacza to, że wariancja błędu nie jest stała.

Przykład – zachorowania na gruźlicę

Poniższa tabela przedstawia liczbę zachorowań na gruźlicę układu oddechowego w latach 1995-2002. Liczba zachorowań została podana w przeliczeniu na 100 tys. ludności. Zakładając liniową zależność pomiędzy rokiem, a ilością zachorowań, dokonać wszechstronnej analizy regresji.

Rok (x_i)	1995	1996	1997	1998	1999	2000	2001	2002
Zachorowania (y_i)	39,7	38,2	34,7	33,1	30,1	28,4	26,3	24,7

Regresja wielokrotna

Wcześniej założyliśmy, że zmienna objaśniana zależy jedynie od jednej zmiennej objaśniającej. Jest to duże uproszczenie. Zdarza się, że badane zjawisko zależy nie tylko od jednego czynnika, ale od wielu. Uogólnieniem regresji prostej jest **regresja wielokrotna** (ang. *multiple regression*) lub **wieloraka** (termin wprowadzony przez K. PEARSONA w 1908 roku), w której uwzględnia się wpływ wielu cech niezależnych na jedną cechę zależną. Załóżmy, że dysponujemy teraz układem k cech $X_1, X_2, \dots, X_k$. Model regresji wielokrotnej można zapisać w postaci:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} = \beta_0 + \beta_1\mathbf{X}_1 + \beta_2\mathbf{X}_2 + \dots + \beta_k\mathbf{X}_k + \boldsymbol{\varepsilon},$$

gdzie $\mathbf{Y}$ jest wektorem obserwacji zmiennej objaśnianej, $\mathbf{X}$ macierzą z pomiarami zmiennych objaśniających (pierwsza kolumna to kolumna jedynek odpowiadająca za wyraz wolny w modelu) a $\boldsymbol{\beta}$ jest wektorem parametrów.

Regresja wielokrotna

W celu estymacji parametrów modelu ponownie używamy MNK otrzymując (oprócz poprzednich założeń, musimy jeszcze przyjąć, że nie istnieje liniowa zależność pomiędzy zmiennymi objaśniającymi):

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Regresja wielokrotna

Częstokroć w przypadku wykorzystania regresji wielorakiej bardziej od prognozy interesuje nas, które zmienne wpływają na badane zjawisko w sposób pobudzający, a które je hamują. Pierwsze z tych czynników nazywamy **stymulantami**, a drugie **destymulantami**. Oczywiście stymulantami są zmienne, które w oszacowanym modelu regresji mają dodatnie wartości parametrów regresji. Destymulanty to zmienne o ujemnych parametrach. Można jeszcze określić zmienne neutralne (nieistotne), czyli takie, które nie mają wpływu na badane zjawisko.

Regresja logistyczna – wprowadzenie

W wielu sytuacjach nie możemy założyć, że zmienna objaśniana jest ciągła. W takiej sytuacji powinniśmy wykorzystać **uogólnione modele liniowe** (*ang. generalized linear models*), w których na zmienną zależną nakłada się rozkład (dopuszczalne są rozkłady pochodzące z tzw. wykładniczej rodziny rozkładów: np. rozkład normalny, wykładniczy, gamma, POISSONA, dwumianowy, geometryczny oraz wielomianowy). Poza tym, aby uwzględnić również nieliniowy charakter zależności wprowadza się tzw. **funkcję wiążącą** (*ang. link function*) h , która ma następującą własność:

$$h(\mathbb{E}(Y|X)) = X\beta.$$

Zauważmy, że jeśli funkcja wiążąca jest identycznością ($h(x) = x$), a zmienna objaśniana ma rozkład normalny, to model ten sprowadza się do modelu regresji liniowej.

Regresja logistyczna – wprowadzenie


Szczególnym i bardzo ważnym przykładem uogólnionego modelu liniowego jest **regresja logistyczna** (*ang. logistic regression*). Formalnie w tym przypadku zakładamy, że $Y \sim b(p)$. Oznacza, to, że zmienna objaśniana przyjmuje tylko dwie wartości (najczęściej jest to zmienna binarna). Modelujemy prawdopodobieństwo wystąpienia sukcesu p . Jako funkcja wiążąca używana jest **funkcja logitowa** (*ang. logit function*):

$$\text{logit}(p) = \ln \frac{p}{1-p}.$$

Prawdopodobieństwo p jest następnie szacowane jako:

$$p = \frac{1}{1 + \exp(-\mathbf{X}\beta)}.$$

Regresja logistyczna – wprowadzenie



Regressja logistyczna – iloraz szans

Interpretacji podlega **iloraz szans** (*ang. odds ratio*), który można wyrazić jako

$$\ln(\text{OR}) = \ln \frac{p}{1-p} = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k.$$

Jeżeli $e^{\beta_j} > 1$, to zmienna X_j działa stymulująco na możliwość wystąpienia badanego zjawiska, w przeciwnym razie działa ograniczająco (jeżeli $e^{\beta_j} = 1$, to zmienna X_j nie ma wpływu na badane zjawisko).

Schema di interpretazione dei valori di Rischio Relativo e Odds Ratio

