

Uczenie maszynowe w Pythonie od podstaw

prof. UAM dr hab. Tomasz Górecki

`tomasz.gorecki@amu.edu.pl`

Zakład Statystyki Matematycznej i Analizy Danych
Wydział Matematyki i Informatyki
Uniwersytet im. Adama Mickiewicza w Poznaniu

XENSTATS

Wprowadzenie


Redukcja wymiaru (*ang. dimensionality reduction, dimension reduction*) – proces zmniejszania liczby zmiennych branych pod uwagę podczas analizy, w taki sposób aby zachować jak najwięcej istotnych informacji. Redukcja wymiaru może polegać na:

- 1 Selekcji cech (*ang. feature selection*) – ograniczeniu zbioru zmiennych według pewnych reguł (np. cechy nadmiernie skorelowane ze sobą, cechy nieistotne statystycznie)
- 2 Ekstrakcji cech (*ang. feature extraction*) – tworzeniu nowych cech pochodnych z początkowego zestawu danych celem uzyskania mniejszego zbioru zmiennych.

Idea

Analiza składowych głównych (ang. principal components analysis – PCA), zwana również dekompozycją według wartości osobliwych (SVD) lub dekompozycją spektralną, jest popularną techniką redukcji wymiarowości danych (liczby cech). Jest to metoda nieparametryczna, a co za tym idzie nie wymaga żadnych założeń, co do rozkładów badanych danych. W metodzie tej chcemy zastąpić zbiór skorelowanych cech (jeśli zmienne nie są skorelowane, PCA nie daje redukcji danych) przez małą liczbę nieskorelowanych tzw. **składowych głównych**, które razem mogą wyjaśnić prawie całą zmienność danych. Pierwsza składowa wyjaśnia najwięcej zmienności (składowe są kombinacjami liniowymi wejściowych zmiennych). Druga składowa wybierana jest w taki sposób, aby nie była skorelowana z pierwszą i wyjaśniała jak najwięcej z pozostałej zmienności.

Idea



Ładunki i wyniki

W rezultacie otrzymujemy tyle składowych (są wzajemnie ortogonalne) ile było zmiennych oryginalnych, ale najczęściej jedynie kilka z nich wyjaśnia prawie całą zmienność danych. Jako wynik otrzymujemy najczęściej dwa elementy: **ładunki** (ang. loadings) oraz **wyniki** (ang. scores). Ładunki to współczynniki pokazujące wkład poszczególnych zmiennych oryginalnych w tworzeniu składowych głównych. Im wartość bezwzględna z ładunku większa tym zmienna ma większy wkład w budowę składowej głównej. Wyniki są współrzędnymi obserwacji w nowym układzie współrzędnych utworzonym przez składowe główne, to one najczęściej podlegają wizualizacji.

Liczba składowych

Jeśli chcemy zredukować wymiar danych musimy się zastanowić ile składowych wybrać do dalszej analizy. Najczęściej decyzję tę podejmuje się bazując na **wykresie osypiska (piargowym)**. Jako optymalną liczbę czynników wybieramy tę, gdzie wykres się znacząco spłaszcza. Drugim popularnym kryterium jest ustalenie pewnego poziomu wariancji jaki muszą wyjaśnić składowe główne (najczęściej 90%). Kryterium osypiska prowadzi niekiedy do odrzucenia zbyt wielu czynników, ale w typowych sytuacjach (niezbyt dużo czynników i sporo obserwacji) radzi sobie całkiem dobrze.

Wizualizacja

Na koniec możemy zwizualizować nowe dane na jednym wykresie, na którym jako punkty będą przedstawione poszczególne obserwacje w układzie dwóch pierwszych składowych głównych, natomiast wektory oznaczać będą cechy. Kierunek wektorów pokazuje wpływ tych cech odpowiednio na pierwszą i drugą składową. Kąt przecięcia strzałek jest proporcjonalny do zależności pomiędzy cechami (dokładnie iloczyn skalarny odpowiednich wektorów wyznacza korelację), a ich długość odzwierciedla odchylenie standardowe. Tego typu wykres nazywa się **biplotem**.

Niezmienność

Składowe główne **nie są niezmiennicze** względem zmiany skali zmiennych oryginalnych. Oznacza to, że przeskalowanie danych zmienia wyniki analizy metodą PCA. Z tego względu składowe główne uzyskane z macierzy kowariancji oraz korelacji różnią się. W przypadku dużych różnic w wariancjach lub cech mierzonych na różnych skalach należy wpierw przeskalować dane (działać na macierzy korelacji).

t-SNE

Metoda **t-SNE** to stochastyczna metoda porządkowania sąsiadów w oparciu o rozkład t (ang. t-Distributed Stochastic Neighbor Embedding). Jest to nieliniowa i nienadzorowana technika stosowana przede wszystkim do eksploracji i wizualizacji danych wielowymiarowych.



van der Maaten, L.J.P., Hinton, G.E. (2008). Visualizing Data Using t-SNE. *Journal of Machine Learning Research* 9:2579–2605.

t-SNE

t-SNE vs PCA

- 1 t-SNE jest metodą probabilistyczną. Czasami w t-SNE różne przebiegi z tymi samymi hiperparametrami mogą dawać różne wyniki, podczas gdy dla PCA zawsze będzie to ten sam wynik.
- 2 PCA jest techniką liniowej redukcji wymiarów, która dąży do maksymalizacji wariancji. Zatem polega głównie na tym aby różne punkty umieszczać daleko od siebie w reprezentacji niższego wymiaru. Może to prowadzić do kiepskiej wizualizacji szczególnie w przypadku nieliniowych struktur.
- 3 t-SNE w przeciwieństwie do PCA zachowuje odległości pomiędzy parami odwzorowując nieliniowość i jest w stanie zinterpretować złożoną zależność pomiędzy cechami.
- 4 t-SNE jest drogi obliczeniowo. W przypadku większych próbek i dużej liczbie wymiarów wyliczenie t-SNE może potrwać nawet kilka godzin, podczas gdy PCA zakończy się w kilka sekund lub minut.

UMAP

Metoda UMAP (ang. Uniform Manifold Approximation and Projection) jest nieliniowym rozszerzeniem metody PCA. Jest jednak dużo bardziej efektywna i dokładna. UMAP produkuje podobne lub lepsze reprezentacje do t-SNE, jako że zachowuje więcej globalnych cech danych, i jest stabilniejszy. Ponadto UMAP jest wydajniejszy od t-SNE.

W pierwszym kroku wyliczane są odległości w wysoko wymiarowej (oryginalnej) przestrzeni, następnie są rzutowane na niższą wymiarową przestrzeń i wyznaczane są odległości między punktami w tej nowej przestrzeni. Następnie używana jest metoda gradientu stochastycznego aby zminimalizować różnice pomiędzy tymi odległościami.



McInnes, L., Healy, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. arXiv:1802.03426v2

Idea

Jedną z wad metody PCA jest możliwość używania jedynie zmiennych ilościowych, kolejnym konieczność posiadania pełnych danych z doświadczenia (nie da się użyć PCA jeśli mamy wyłącznie informacje o podobieństwie obiektów). **Skalowanie wielowymiarowe** (ang. multidimensional scaling (MDS)) pozbawione jest tych wad. Jest to metoda redukcji wymiarowości bazująca na macierzy niepodobieństwa pomiędzy obiektami. Celem tej metody jest wyznaczenie współrzędnych obserwacji w nowym układzie, w taki sposób aby odległości pomiędzy obiektami w tym nowym układzie współrzędnych były maksymalnie podobne do oryginalnych odległości pomiędzy obserwacjami.

Rodzaje skalowania

- Metryczne – minimalizujemy sumę modułów (kwadratów) różnic pomiędzy oryginalnymi odległościami oraz odległościami w nowo powstałym układzie współrzędnych. Zakładamy, że dysponujemy jedynie cechami ilościowymi. Jeśli dysponujemy oryginalnym zbiorem danych, a nie macierzą niepodobieństw, skalowanie wielowymiarowe jest tożsame z analizą składowych głównych (na macierzy kowariancji) i nazywa się **klasycznym skalowaniem wielowymiarowym** (ang. principal coordinates analysis). Skalowanie metryczne używamy gdy mamy przekonanie, że konkretna odległość w sposób właściwy reprezentuje odległości pomiędzy obiektami.

Rodzaje skalowania

- Niemetryczne – poszukujemy optymalnego porządku pomiędzy odległościami, przy czym nie ma znaczenia sama wartość odległości, jedynie ich porządek. Dane mogą być mieszaniną danych jakościowych i ilościowych. W przypadku danych jakościowych musi istnieć pomiędzy nimi pewien porządek. W przeciwieństwie do klasycznego skalowania nie istnieje analityczne rozwiązanie tego zagadnienia. Co gorsza procedura poszukiwania rozwiązania jest iteracyjna i wymaga początkowej konfiguracji punktów. Ta metoda jest częściej używana w praktyce.

Idea

Analiza korespondencji (ang. correspondence analysis (CA)) to technika, która pozwala graficznie przedstawić w niskowymiarowej przestrzeni dane (najczęściej jakościowe) zawarte w tablicy wielodzidelczej. Stosowana jest szczególnie często w naukach biologicznych oraz społecznych, z uwagi na często występujące macierze kontyngencji. Jeśli stwierdzimy zależność badanych cech możemy przejść do właściwej analizy korespondencji. Chcemy dokonać rzutowania oryginalnych danych na przestrzeń o jak najmniejszym wymiarze, przy czym w tej nowej przestrzeni powinna być zachowana możliwie najlepiej odległość χ^2 . O tym ile oryginalnej odległości zostało zachowane mówi tzw. **inercja**. Klasyczna analiza korespondencji jest właściwie metodą metrycznego skalowania wielowymiarowego z odległością χ^2 jako miarą niepodobieństwa.