

Uczenie maszynowe w Pythonie od podstaw

prof. UAM dr hab. Tomasz Górecki

`tomasz.gorecki@amu.edu.pl`

Zakład Statystyki Matematycznej i Analizy Danych
Wydział Matematyki i Informatyki
Uniwersytet im. Adama Mickiewicza w Poznaniu

XENSTATS

Idea

Analiza skupień (*ang. cluster analysis*) jest narzędziem analizy danych służącym do grupowania n obiektów, opisanych za pomocą wektora p -cech, w K niepustych, rozłącznych i możliwie „jednorodnych” grup – skupień. Obiekty należące do danego skupienia powinny być „podobne” do siebie, a obiekty należące do różnych skupień powinny być z kolei możliwie mocno „niepodobne” do siebie. Głównym celem tej analizy jest wykrycie z zbiorze danych, tzw. „naturalnych” skupień, czyli skupień, które dają się w sensowny sposób interpretować.

Algorytm zachłanny

Zwróćmy uwagę, że pod tym terminem kryje się szereg różnych algorytmów. Konceptyjnie, najprostszym byłby następujący. Ustalamy liczbę skupień K oraz kryterium optymalnego podziału obiektów. Przeszukujemy wszystkie możliwe podziały n obiektów na K skupień, wybierając najlepszy podział ze względu na przyjęte kryterium optymalności. Bezpośrednie sprawdzenie wszystkich możliwych podziałów jest jednak, nawet przy niewielkim n , praktycznie niemożliwe. Ich liczba bowiem jest równa


$$\frac{1}{K!} \sum_{k=1}^K (-1)^{K-k} \binom{K}{k} k^n$$

i np. dla $n = 100$ obiektów i $K = 4$ skupień jest rzędu 10^{58} .


Algorytmy hierarchiczne – idea

Najprostszą i zarazem najczęściej używaną metodą analizy skupień jest **metoda hierarchiczna**. Wspólną cechą krokowych algorytmów tej metody jest wyznaczanie skupień poprzez łączenie (aglomerację) powstałych, w poprzednich krokach algorytmu, mniejszych skupień. Inne wersje tej metody zamiast idei łączenia skupień, bazują na pomysłach ich dzielenia. Podstawą wszystkich algorytmów tej metody jest odpowiednie określenie miary niepodobieństwa obiektów.

Algorytmy hierarchiczne – idea



Algorytmy hierarchiczne – idea



Algorytmy hierarchiczne – algorytm aglomeracyjny

W pierwszym kroku każdy z obiektów tworzy oddzielne skupienie. Zatem skupień tych jest n . W kroku drugim w jedno skupienie połączone zostają dwa najbardziej podobne do siebie obiekty – w sensie wybranej miary niepodobieństwa obiektów. Otrzymujemy zatem $n - 1$ skupień. Postępując analogicznie, tzn. łącząc (wiążąc) ze sobą skupienia złożone z najbardziej podobnych do siebie obiektów, w każdym następnym kroku, liczba skupień maleje o jeden. Obliczenia prowadzimy do momentu uzyskania zadeklarowanej, końcowej liczby skupień K lub do połączenia wszystkich obiektów w jedno skupienie.

Algorytmy hierarchiczne – dendrogram

Graficzną ilustracją algorytmu jest **dendrogram** (*ang. dendrogram*), czyli drzewo binarne, którego węzły reprezentują skupienia, a liście obiekty. Liście są na poziomie zerowym, a węzły na wysokości odpowiadającej mierze niepodobieństwa pomiędzy skupieniami reprezentowanymi przez węzły potomki.

Algorytmy hierarchiczne – metody wiązania skupień

Algorytm ten wykorzystuje nie tylko miary niepodobieństwa pomiędzy obiektami, potrzebne są nam również **metody wiązania skupień**. Niech R i S oznaczają skupienia, a $\rho(R, S)$ oznacza miarę niepodobieństwa pomiędzy nimi. Poniżej podano najczęściej wykorzystywane sposoby jej określenia.

Algorytmy hierarchiczne – metoda pojedynczego wiązania

Metoda pojedynczego wiązania (najbliższego sąsiedztwa) (*ang. single linkage*). Miara niepodobieństwa pomiędzy dwoma skupieniami jest określona jako najmniejsza miara niepodobieństwa między dwoma obiektami należącymi do różnych skupień:

$$\rho(R, S) = \min_{i \in R, j \in S} \rho(\mathbf{x}_i, \mathbf{x}_j).$$

Zastosowanie tego typu odległości prowadzi do tworzenia wydłużonych skupień, tzw. łańcuchów. Pozwala na wykrycie obserwacji odstających, nie należących do żadnej z grup, i warto przeprowadzić klasyfikację za jej pomocą na samym początku, aby wyeliminować takie obserwacje i przejść bez nich do właściwej części analizy.

Algorytmy hierarchiczne – metoda pojedynczego wiązania

Metoda pełnego wiązania (najdalszego sąsiedztwa) (*ang. complete linkage*). Miara niepodobieństwa pomiędzy dwoma skupieniami jest określona jako największa miara niepodobieństwa między dwoma obiektami należącymi do różnych skupień:

$$\rho(R, S) = \max_{i \in R, j \in S} \rho(\mathbf{x}_i, \mathbf{x}_j).$$

Metoda ta jest przeciwieństwem metody pojedynczego wiązania. Jej zastosowanie prowadzi do tworzenia zwartych skupień o małej średnicy. Ma tendencję do dzielenia dużych skupień.

Algorytmy hierarchiczne – metoda pojedynczego wiązania

Metoda średniego wiązania (*ang. average linkage*). Miara niepodobieństwa pomiędzy dwoma skupieniami jest określona jako średnia miara niepodobieństwa między wszystkimi parami obiektów należących do różnych skupień:

$$\rho(R, S) = \frac{1}{n_R n_S} \sum_{i \in R} \sum_{j \in S} \rho(\mathbf{x}_i, \mathbf{x}_j),$$

gdzie n_R i n_S są liczbami obiektów wchodzących w skład skupień R i S odpowiednio.

Metoda ta jest swoistym kompromisem pomiędzy metodami pojedynczego i pełnego wiązania. Ma ona jednak zasadniczą wadę. W odróżnieniu od dwóch poprzednich wykorzystywana w niej miara niepodobieństwa nie jest niezmiennicza ze względu na monotoniczne przekształcenia miar niepodobieństwa pomiędzy obiektami.

Algorytmy hierarchiczne – inne metody wiązania skupień


Omówione metody wiązania skupień, choć najczęściej stosowane, nie są jedyne. W przypadku gdy liczebności skupień są zdecydowanie różne, zamiast metodą średniego wiązania możemy posługiwać się jej ważonym odpowiednikiem. Wagami są wtedy liczebności poszczególnych skupień. Inna popularna metoda wiązania skupień pochodzi od WARDA (1963). Do obliczania miary niepodobieństwa pomiędzy skupieniami wykorzystuje on podejście analizy wariancji. Metoda daje bardzo dobre wyniki (grupy bardzo homogeniczne), jednak ma skłonność do tworzenia skupień o podobnych rozmiarach. Często nie jest też w stanie zidentyfikować grup o szerokim zakresie zmienności poszczególnych cech oraz niewielkich grup.

Metoda K -średnich – idea

Najbardziej popularnym, niehierarchicznym algorytmem analizy skupień jest **algorytm K -średnich** (ang. *k-means*).

Przyporządkowanie n obiektów do zadanej liczby skupień K , odbywa się niezależnie dla każdej wartości K – nie bazując na wyznaczonych wcześniej mniejszych lub większych skupieniach. Niech C_K oznacza funkcję, która każdemu obiektowi (dokładnie jego numerowi), przyporządkowuje numer skupienia do którego jest on przyporządkowany (przy podziale na K skupień). Zakładamy, że wszystkie cechy są ilościowe o wartościach rzeczywistych (przestrzeń próby to $\mathbb{R}^p$). Główną ideą metody K -średnich jest taka alokacja obiektów, która minimalizuje zmienność wewnątrz powstałych skupień, a co za tym idzie maksymalizuje zmienność pomiędzy skupieniami.

Metoda K -średnich – idea



Metoda K -średnich – modyfikacje

Istnieje wiele modyfikacji powyższego algorytmu. Przykładowo, losowe rozmieszczenie elementów w skupieniach – krok pierwszy algorytmu, zastąpione zostaje narzuconym podziałem, mającym na celu szybsze ustabilizowanie się algorytmu.

Wszystkie wersje algorytmu K -średnich są zbieżne. Nie gwarantują one jednak zbieżności do optymalnego rozwiązania. Niestety, w zależności od początkowego podziału, algorytm zbiega do zazwyczaj różnych lokalnie optymalnych rozwiązań. W związku z tym, aby uzyskać najlepszy podział, zaleca się często wielokrotne stosowanie tego algorytmu z różnymi, wstępnymi rozmieszczeniami obiektów.

Metoda K -średnich – wybór K – zarys

Z powodu łatwej możliwości wizualizacji coraz popularniejsza staje się miara zwana **zarysem** (ang. *silhouette*). Dla każdej obserwacji i niech $a(i)$ będzie średnią miarą niepodobieństwa pomiędzy nią, a wszystkimi obserwacjami z tej samej grupy (im mniejsza wartość tym lepsze dopasowanie obserwacji do grupy). Następnie znajdujemy średnie odległości obserwacji i do pozostałych skupień. Przez $b(i)$ oznaczmy najmniejszą z tych średnich (średnia odległość do najbliższego skupienia, do którego i nie należy). Zarys definiujemy jako:

$$s_i = \frac{b(i) - a(i)}{\max(a(i), b(i))}.$$

Miara ta przyjmuje wartości od -1 do 1 . Obserwacje, dla których s_i jest bliskie 1 są poprawnie przydzielone, jeśli s_i jest bliskie 0 obserwacja leży na granicy skupień, jeśli natomiast s_i jest ujemne obserwacja znajduje się w złym skupieniu.

Metoda K -średnich – wybór K – współczynnik zarysu

Średnia wartość zarysu $\bar{s}_k$, dla każdego skupienia mówi o tym jak dobrze dane są przydzielone do tego skupienia. Z tego względu średni zarys dla całego zbioru danych może służyć jako miara jakości podziału. **Współczynnik zarysu** ma postać $SC = \max_k \bar{s}_k$, i jego interpretacja została zawarta w poniższej tabeli.

SC	Interpretacja
0,71-1,00	Silna struktura
0,51-0,70	Istotna struktura
0,26-0,50	Słaba struktura
$\leq 0,25$	Brak struktury

Zarys podlega wizualizacji za pomocą **wykresu zarysu**.

DBSCAN – analiza skupień bazująca na gęstościach punktów

Poprzednio omówione metody są dostosowane do wykrywania skupień sferycznych lub wypukłych. Innymi słowy działają dobrze dla zwartych i dobrze rozdzielonych skupień. Dodatkowo duży wpływ na wyniki mają obserwacje odstające oraz szum w danych.


DBSCAN – analiza skupień bazująca na gęstościach punktów

Algorytm **DBSCAN** (*ang. Density-Based Spatial Clustering and Application with Noise*) został zaproponowany w 1996 roku przez Ester i innych. Zalety:


- Nie wymaga określenia przez użytkownika liczby skupień.
- Pozwala znaleźć dowolne kształty skupień.
- Pozwala zidentyfikować obserwacje odstające.

DBSCAN – analiza skupień bazująca na gęstościach punktów


Główna idea wywodzi się z ludzkiej intuicji. Na przykład na poniższym obrazku widać, że mamy (bazując na gęstości punktów) cztery skupienia oraz kilka punktów odstających.



database 1



database 2




database 3

DBSCAN – analiza skupień bazująca na gęstościach punktów

Głównym celem jest identyfikacja gęstych regionów, które mogą być widziane jako regiony z dużą liczbą punktów. Istotne są dwa parametry: „epsilon” (eps) oraz „minimum points” (MinPts). Pierwszy z nich określa promień sąsiedztwa punktu x . Drugi definiuje minimalną liczbę punktów sąsiedztwa w promieniu epsilon. Każdy punkt zbioru danych z liczbą sąsiadów większą bądź równą MinPts jest nazywany punktem rdzeniowym (ang. core point). Punkt jest nazywany punktem granicznym (ang. border point) jeśli liczba jego sąsiadów jest mniejsza od MinPts, ale należy on do sąsiedztwa pewnego punktu rdzeniowego. Jeśli punkt nie jest rdzeniowym ani granicznym to nazwany jest punktem szumu lub odstającym (ang. noise point).

DBSCAN – analiza skupień bazująca na gęstościach punktów



Niech $\text{MinPts} = 6$. Punkt x jest tutaj punktem rdzeniowym ponieważ w jego otoczeniu o promieniu ϵ znajduje się 6 punktów. y jest punktem granicznym ponieważ w jego otoczeniu jest mniej niż 6 punktów (dokładnie 5), ale należy on do otoczenia punktu rdzeniowego x . Natomiast punkt z jest punktem odstającym (ma dokładnie 2 sąsiadów, którzy nie są punktami rdzeniowymi).

DBSCAN – analiza skupień bazująca na gęstościach punktów

