

Uczenie maszynowe w Pythonie od podstaw

prof. UAM dr hab. Tomasz Górecki

`tomasz.gorecki@amu.edu.pl`

Zakład Statystyki Matematycznej i Analizy Danych
Wydział Matematyki i Informatyki
Uniwersytet im. Adama Mickiewicza w Poznaniu

XENSTATS

Wstęp

Problem **klasyfikacji** (*ang. classification*) zwany też analizą dyskryminacyjną, sprowadza się do określenia przydziału obiektów opisanych za pomocą wartości wielu cech (atrybutów) do jednej z wcześniej ustalonych klas. Klasom przypisane są kody zwane etykietami. Pierwszym elementem systemu uczącego się pod nadzorem jest **próbna ucząca** (*ang. learning (train) sample*) składająca się z n niezależnych par zmiennych $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$, gdzie $\mathbf{X}_i$ jest wektorem zaobserwowanych cech na obiekcie pochodzącym z klasy o etykiecie Y_i , $i = 1, \dots, n$.

Wstęp

Drugim elementem jest funkcja określona na przestrzeni wartości cech o wartościach w zbiorze etykiet, zwana **klasyfikatorem** (*ang. classifier*), skonstruowana na bazie próby uczącej. Trzecim elementem jest **ocena skuteczności działania klasyfikatora** (ocena wartości błędu klasyfikacji lub trafności klasyfikacji).

Pojęcia wstępne

Założmy, że dysponujemy K niezależnymi, prostymi próbami losowymi o liczebnościach, odpowiednio: $n_1, n_2, \dots, n_K$, pobranymi z K różnych populacji (klas, grup):

$$(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n),$$

gdzie $\mathbf{X}_i = (X_{i1}, X_{i2}, \dots, X_{ip})' \in \mathcal{X} \subset \mathbb{R}^p$ jest i -tą obserwacją, natomiast Y_i jest etykietą populacji, do której ta obserwacja należy, przyjmującą wartości w pewnym skończonym zbiorze $\mathcal{Y}$, $i = 1, 2, \dots, n$, $n = n_1 + n_2 + \dots + n_K$.

Próbę $\mathcal{L}_n = \{(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)\}$ nazywać będziemy **próbą uczącą** (*ang. training sample*). Interesuje nas problem predykcji etykiety Y na podstawie wektora cech $\mathbf{X}$. Problem ten nazywany jest **klasyfikacją, dyskryminacją lub rozpoznawaniem wzorców**.

Pojęcia wstępne

Reguła klasyfikacyjna, zwana krótko **klasyfikatorem**, jest funkcją $d: \mathcal{X} \rightarrow \mathcal{Y}$. Gdy obserwujemy nowy wektor $\mathbf{X}$, to prognozą etykiety Y jest $d(\mathbf{X})$.



Parametry vs hiperparametry

Parametry modelu są wyznaczane w czasie uczenia, są zatem wynikiem uczenia modelu (np. współczynniki regresji).

Hiperparametry są ustalane przed uczeniem modelu i, w przeciwieństwie do parametrów, nie mogą być wyznaczone podczas uczenia. Stosuje się dwa podstawowe podejścia do optymalizacji hiperparametrów:

- Przeszukiwanie po siatce (*ang. grid search, exhaustive search*).
- Przeszukiwanie losowe (*ang. random search*).
- Przeszukiwanie adaptacyjne (*ang. adaptive selection*).

Parametry vs hiperparametry



Grid Search

Random Search

Adaptive Selection


Parametry vs hiperparametry

Przeszukiwanie losowe jest zalecane kiedy przeszukiwana przestrzeń parametrów jest wysoko wymiarowa (więcej niż 3 wymiary). W takiej sytuacji za jego pomocą możemy przeszukać szersze spektrum wartości hiperparametrów ponieważ przeszukiwanie po siatce jest zazwyczaj dużo bardziej złożone obliczeniowo.

Idea

CLASSIFICATION

Classification problems are when we are training a model to predict qualitative targets. For example: gender or a type of fruit.



Ocena jakości

Proces konstruowania klasyfikatora $\hat{d}$ nazywany jest **uczeniem się**, **uczeniem pod nadzorem** lub **uczeniem się z nauczycielem**. Jakość klasyfikatora $\hat{d}$ mierzona jest za pomocą warunkowego prawdopodobieństwa błędu

$$e(\hat{d}) = \mathbb{P}(\hat{d}(\mathbf{X}) \neq Y \mid \mathcal{L}_n),$$

gdzie para losowa $(\mathbf{X}, Y)$ jest niezależna od próby uczącej $\mathcal{L}_n$. Wielkość $e(\hat{d})$ nazywamy **aktualnym poziomem błędu** klasyfikatora $\hat{d}$. Ocenę błędu klasyfikacji będziemy nazywać **błędem klasyfikacji** (*ang. classification error rate*). Przeciwnieństwem błędu klasyfikacji jest **dokładność klasyfikacji** (*ang. accuracy*).

Ocena jakości

W najlepszej sytuacji jesteśmy wtedy, gdy dysponujemy m -elementową **próbą testową** (ang. *test sample*) $\mathcal{T}_m$ niezależną od próby uczącej $\mathcal{L}_n$. W takiej sytuacji za błąd klasyfikacji przyjmujemy procent obserwacji pochodzących z próby testowej błędnie zaklasyfikowanych za pomocą reguły klasyfikacyjnej skonstruowanej na podstawie próby uczącej. W przypadku gdy nie dysponujemy niezależną próbą testową, do estymacji używamy jedynie próby uczącej.

Ocena jakości

Naturalną oceną aktualnego poziomu błędu jest wtedy wartość **estymatora ponownego podstawienia** (resubstytucji, *ang. resubstitution error rate*). Wartość tego estymatora uzyskuje się poprzez klasyfikację regułą $\hat{d}$ tych samych obserwacji, które służyły do jej konstrukcji. Oznacza to, iż próba ucząca jest zarazem próbą testową. Estymator ten jest więc obciążonym estymatorem wielkości $e(\hat{d})$ i zaniża jej rzeczywistą wartość.


Ocena jakości

Jednym ze sposobów redukcji obciążenia powyższego estymatora przy zastosowaniu próby uczącej jako jednocześnie próby testowej jest tzw. metoda **podziału próby** na dwa podzbiory: próbę uczącą i próbę testową. Wówczas klasyfikator konstruuje się za pomocą pierwszego z nich, drugi natomiast służy do konstrukcji estymatora. Wykorzystanie tylko części informacji w celu uzyskania reguły klasyfikacyjnej prowadzi jednak często do zawyżenia wartości estymatora błędu. Rozwiązaniem tego problemu jest metoda **sprawdzania krzyżowego z pojedynczym usuwaniem** (*ang. leave-one-out cross-validation (LOOCV, nCV)*). W takiej sytuacji usuwamy kolejne obserwacje z próby uczącej i konstruujemy klasyfikator w oparciu o taką pomniejszoną o jedną próbę uczącą. Usunięty element jest następnie klasyfikowany za pomocą tak wyznaczonej metody. Frakcja błędnie zaklasyfikowanych w taki sposób obserwacji jest uznawana za błąd klasyfikacji.

Ocena jakości

Procedura ta w każdym z n etapów jest w rzeczywistości metodą podziału próby dla przypadku jednoelementowego zbioru testowego. Każda obserwacja próby jest użyta do konstrukcji klasyfikatora $\hat{d}$. Każda z nich jest też (dokładnie jeden raz) elementem testującym. Estymator ten, choć granicznie nieobciążony, ma większą wariancję. Ponadto wymaga on konstrukcji n klasyfikatorów, co dla dużych n oznacza znaczący wzrost obliczeń. Rozwiązaniem pośrednim jest **metoda rotacyjna**, zwana też **k -krokową metodą sprawdzania krzyżowego** (*ang.* *k-fold cross-validation (kCV)*). Polega ona na losowym podziale próby na k podzbiorów, przy czym $k - 1$ z nich tworzy próbę uczącą, natomiast pozostałe – próbę testową. Procedurę tę powtarza się k razy, dla każdego podzbioru rozpatrywanego kolejno jako zbiór testowy.

Ocena jakości



Ocena jakości

Metoda ta daje mniejsze obciążenie błędu niż metoda podziału próby i wymaga mniejszej liczby obliczeń w porównaniu ze sprawdzaniem krzyżowym (jeśli tylko $k < n$). W zagadnieniu estymacji aktualnego poziomu błędu zalecane jest $k = 5$ lub $k = 10$.

W celu redukcji losowości używa się również powtórzeń np. $5 \times 5CV$.

Ocena jakości

Wykorzystywana bywa również metoda **bootstrap** (*ang. bootstrap*) polegająca na wielokrotnym (zaleca się co najmniej 50) losowym podziale zbioru na zbiór uczący i testowy, przy czym losowanie odbywa się ze zwracaniem. Uzyskany zbiór uczący musi mieć taką samą liczebność jak cały badany zbiór. Następnie uczymy metodę na tak otrzymanym zbiorze i testujemy na tych obserwacjach, które nie zostały wylosowane.

Ocena jakości

BOOTSTRAP

Bootstrap simulates obtaining many new datasets by repeated sampling with replacement from the original dataset.

	X_1	X_2
1	1	10
2	2	20
3	3	30



	X_1	X_2
1	1	10
1	1	10
3	3	30

	X_1	X_2
3	3	30
1	1	10
2	2	20

Chris Albon

Macierz pomyłek (przynależności)


Sam błąd klasyfikacji nie wystarczy aby stwierdzić, czy klasyfikator działa dobrze. Po zakończeniu procedury oceny błędu klasyfikacji naszego modelu zostajemy z listą obserwacji testowych, gdzie dla każdej z nich znamy klasę obserwowaną oraz klasę przewidywaną przez nasz model. Zliczając liczbę przypadków dla każdej z kombinacji tych dwóch klas (obserwowanej i przewidywanej) możemy stworzyć tzw. **macierz pomyłek** (*ang. confusion matrix*). Możemy na jej podstawie ocenić błąd modelu: musimy zsumować wartości na głównej przekątnej (obserwacje poprawnie rozpoznane) i podzielić je przez liczbę wszystkich obserwacji testowych.

Macierz pomyłek (przynależności)

CONFUSION MATRIX

Confusion matrices visualize the accuracy of a classifier by comparing the true and predicted classes. Off diagonal squares are incorrect predictions.

Chris Albon




Metoda najbliższego sąsiada (*ang. nearest neighbor method*)


Metoda najbliższego sąsiada (1NN) jest jedną z najpopularniejszych metod klasyfikacji. Jej idea jest prosta i intuicyjna. Nowy obiekt otrzymuje klasę obiektu, który jest najbliżej (w uogólnieniu tej metody, czyli metodzie k najbliższych sąsiadów, klasę która występuje najczęściej pośród jego k sąsiadów). Należy podkreślić, że do oceny odległości może zostać wykorzystana bardzo szeroka klasa funkcji. Jest to metoda nieparametryczna, nie wymaga zatem żadnych założeń co do rozkładów danych w klasach.

Metoda najbliższego sąsiada (*ang. nearest neighbor method*)


1st, 2nd, and 3rd Nearest Neighbors
 of a Test Instance




1-nearest neighbor



2-nearest neighbor



3-nearest neighbor



Metoda najbliższego sąsiada (*ang. nearest neighbor method*)

W praktyce wartość parametru k (liczba sąsiadów) dobiera się eksperymentalnie, stosując bądź to próbę testową bądź metodę sprawdzania krzyżowego. Metoda $1NN$ ma tendencję do bycia zbyt czułą na pewną losowość (błędne sklasyfikowanie lub błędny pomiar cechy) ukrytą w danych. Ponieważ pewne cechy, których wartości są duże mogą niwelować wpływ innych dlatego niezbędna jest normalizacja wartości cech. Dla zmiennych ciągłych używamy:

- normalizacja min-max

$$x = \frac{x - \min(x)}{\max(x) - \min(x)},$$


- standaryzacja

$$x = \frac{x - \bar{x}}{s(x)}$$

Metoda najbliższego sąsiada (*ang. nearest neighbor method*)

Normalizacja jest niezbędna, ponieważ przeprowadza zmienne o różnych jednostkach w wielkości niemianowane i porównywalne. Metoda najbliższego sąsiada jest odporna na występowanie obserwacji odstających oraz zakłóceń. Niestety jej główną wadą jest długi czas obliczeń, który rośnie bardzo szybko wraz ze wzrostem liczby obserwacji. Nie istnieje również możliwość wykorzystywania zmiennych jakościowych, a wyniki klasyfikacji mocno zależą od wybranej miary odległości.


Metoda najbliższego sąsiada (ang. nearest neighbor method)



Drzewa klasyfikacyjne (*ang. classification trees*)

Drzewa klasyfikacyjne – rodzina metod statystycznych z zakresu eksploracji danych, dokonujących, za pomocą diagramów zwanych drzewami, klasyfikacji danych. Drzewo składa się z korzenia oraz gałęzi prowadzących z korzenia do kolejnych węzłów. W każdym węźle sprawdzany jest pewien warunek dotyczący danej obserwacji, i na jego podstawie wybierana jest jedna z gałęzi prowadząca do kolejnego węzła piętro niżej. Na dole znajdują się liście, w których odczytujemy do której z klas należy przypisać daną obserwację. Klasyfikacja danej obserwacji polega na przejściu od korzenia do liścia i przypisaniu do tej obserwacji klasy zapisanej w danym liściu.

Drzewa klasyfikacyjne (ang. classification trees)




Drzewa klasyfikacyjne (*ang. classification trees*)

Każdy podział s jest uwarunkowany przez obserwacje ze zbioru uczącego $\mathcal{L}_n$, należące do danego węzła t . Praktycznie trzeba zatem rozdzielić je na dwa podzbiory możliwie jednorodne ze względu na etykietę klasy. Gdyby zatem w węźle t znajdowały się obserwacje tylko z dwóch klas, to idealnym byłby taki podział, który przypisałby obserwacje uczące z jednej klasy do węzła t_L , a z drugiej klasy do węzła t_R . Dla każdego węzła t określmy pewną miarę $I(t)$ niejednorodności elementów w tym węźle. Stąd, dla każdego podziału s węzła t będziemy mogli zmierzyć niejednorodność elementów w tym węźle oraz w jego potomkach t_L i t_R .

Drzewa klasyfikacyjne (*ang. classification trees*)

Przy tworzeniu drzewa należy unikać zbytniego rozbudowania struktury drzewa, ponieważ wzrasta złożoność opartego na nim modelu, co w konsekwencji prowadzi do trudności w jego interpretacji oraz utraty właściwości generalizacji. Budując zbyt duże drzewo mamy do czynienia z tzw. **efektem przeuczenia** (*ang. overfitting*). Polega on na tym, że drzewo doskonale klasyfikuje obiekty z próby uczącej lecz coraz słabiej (w miarę zwiększania liczby liści) nowe elementy. Aby tego uniknąć wpierw konstruuje się drzewa maksymalnie złożone, a następnie stosuje technikę zwaną **przycinaniem** (*ang. pruning*), która zmniejsza drzewo.


Drzewa klasyfikacyjne (*ang. classification trees*)



Las losowy (*ang. random forest*)

Jest to metoda łączenia wielu drzew klasyfikacyjnych. Wpierw losujemy K prób bootstrapowych (im więcej tym lepiej), dla każdej z nich konstruujemy drzewo klasyfikacyjne w taki sposób, że w każdym węźle losujemy m cech, które będą uczestniczyły w wyborze najlepszego podziału. Drzewa budowane są bez przycinania. Ostatecznie obserwacja klasyfikowana jest poprzez metodę głosowania (*ang. majority voting*). Parametr m powinien być znacznie mniejszy od wymiaru danych p , przyjmuje się najczęściej jego wartość równą $\sqrt{p}$ (klasyfikacja) lub $p/3$ (regresja).

Las losowy (ang. random forest)




Sieci neuronowe (*ang. neural networks*)

Sieć neuronowa to połączona grupa sztucznych komórek nerwowych, która wykorzystuje model matematyczny w celu przetwarzania informacji. Istotną cechą sieci jest możliwość uczenia się, czyli modyfikowania parametrów charakteryzujących poszczególne neurony w taki sposób, by zwiększyć efektywność sieci. Pomysł tej techniki wywodzi się z badań bioelektrycznych sieci utworzonych w mózgu przez neurony i synapsy. W modelu sieci neuronowej węzły (zwane neuronami) są połączone między sobą tworząc sieć węzłów – stąd określenie „sieć neuronowa”. Sztuczne sieci neuronowe składają się najczęściej z trzech warstw: warstwa wejściowa, ukryta i wyjściowa.

Sieci neuronowe (ang. neural networks)

Neural Networks

Color Guided Matrix Multiplication for a Binary Classification Task
with N = 4




<http://playground.tensorflow.org/>


Sieci neuronowe (*ang. neural networks*)

Głębsze architektury pozwalają na rozwiązywanie trudniejszych problemów. Cała ta złożoność może być jednak zwinięta w jedną dużą warstwę ukrytą. Sieć trójwarstwowa ma taką samą moc jak sieć czterowarstwowa, ale nie jest tak samo efektywna: sieć trójwarstwowa o konfiguracji $3 - 10 - 8$ ma 118 parametrów ($3 \times 10 + 10 \times 8 + 8$), podczas gdy sieć czterowarstwowa o konfiguracji $3 - 10 - 3 - 8$ ma jedynie 95 parametrów ($3 \times 10 + 10 \times 3 + 3 \times 8 + 3 + 8$). Na tym właśnie polega siła **głębokich sieci neuronowych** (*ang. deep neural network*) – umożliwiają one badanie złożonych modeli stosując stosunkowo niewiele parametrów.

Sieci neuronowe (*ang. neural networks*)




Sieci neuronowe (*ang. neural networks*)



Metoda wektorów nośnych (*ang. support vector machines*)

Metoda wektorów nośnych jest metodą, która polega na transformacji obserwacji (za pomocą tzw. triku jądrowego (*ang. kernel trick*)), które nie są liniowo separowalne (czyli nie da się ich podzielić na klasy hiperpłaszczyznami), do przestrzeni o wyższym wymiarze, w której być może staną się już separowalne liniowo. Dzięki trikowi jądrowego nie ma potrzeby transformacji punktów, wystarczy jedynie mierzyć odległości w wyższym wymiarze.

Metoda wektorów nośnych (*ang. support vector machines*)



Metoda wektorów nośnych (*ang. support vector machines*)

